

三门问题

ZYX

三门问题非常有趣，它背后的本质是贝叶斯统计的思维。

三门问题如下：三扇门 (A,B,C) 其中随机的一扇门后是汽车，另两扇门后面是羊（不值钱之意），主持人知道哪扇门后有汽车，但不会告诉嘉宾。嘉宾来抽奖，规则如下：

Step 1: 嘉宾需要先做出最初的选择，假设选的是 A 门，注意：主持人心里知道嘉宾选的是不是汽车，这时主持人就会在剩下的两个门 B 和 C 中，打开不是汽车的一扇门。就是说，假设嘉宾选错了（A 门后是羊），主持人就打开剩下两个门中不是汽车的那扇；如果嘉宾选对了（A 门后是汽车），主持人就在剩下的两个不是汽车的门中随机选一扇打开。

Step 2: 现在嘉宾可以在未打开的 2 个门中，做出第二次选择。问：这时嘉宾需要改变主意，换成另外一个门吗？

初看这个问题，直觉就是换不换都一样，在 2 个门中做选择，选中的概率不都是 $1/2$ 吗？就像在第一次选择中，三个门的概率是平等的 $1/3$ 。但是答案很违反直觉，此时需要更换门才有更大的抽中概率！在主持人做出选择后，剩下的两扇门后是汽车的概率不再平等，而是发生了变化。

记 $P(A), P(B), P(C)$ 为汽车在 A,B,C 门后的概率。那么显然： $P(A) = P(B) = P(C) = 1/3$ ，这叫做**先验概率**，也就是实验之前的概率。主持人做出选择这个动作，相当于做了一次实验（测试），它的测试数据（打开了另一扇门）就是新的信息，可以利用这个信息把先验概率更新为**后验概率**，也就是实验之后的概率。这个新的信息，叫做**似然概率**。似然概率代表观测过程，是对测量过程不确定性的刻画，传感器的准确度即可命名为似然。“似”就是“像”，“然”就是“这样”，“似然”就是“像这样”，英文是 likelihood。

不失一般性，假设嘉宾初选 A 门，然后主持人打开的是 B 门，那么我们需要计算出此时汽车在 A 门和 C 门之后的概率。如前所述，主持人就是这个传感器，他做出的选择就是测试结果，考察“主持人打开 B 门”这个观测过程的各个条件概率，也就是似然概率，易知： $P(\text{开}B|A) = 1/2, P(\text{开}B|B) = 0, P(\text{开}B|C) = 1$ 。

根据贝叶斯公式（其推导过程见附录）：

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A|B)P(B)}{P(A)} = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})} \quad (1)$$

可以计算出，在打开 B 门后，汽车在 A 门之后的概率为：

$$\begin{aligned} P(A|\text{开}B) &= \frac{P(\text{开}B|A)P(A)}{P(\text{开}B)} = \frac{P(\text{开}B|A)P(A)}{P(\text{开}B|A)P(A) + P(\text{开}B|B)P(B) + P(\text{开}B|C)P(C)} \\ &= \frac{\frac{1}{2} \times \frac{1}{3}}{\frac{1}{2} \times \frac{1}{3} + 0 \times \frac{1}{3} + 1 \times \frac{1}{3}} = \frac{1}{3} \end{aligned}$$

以及，在打开 B 门后，汽车在 C 门之后的概率为：

$$\begin{aligned} P(C|\text{开}B) &= \frac{P(\text{开}B|C)P(C)}{P(\text{开}B)} = \frac{P(\text{开}B|C)P(C)}{P(\text{开}B|A)P(A) + P(\text{开}B|B)P(B) + P(\text{开}B|C)P(C)} \\ &= \frac{1 \times \frac{1}{3}}{\frac{1}{2} \times \frac{1}{3} + 0 \times \frac{1}{3} + 1 \times \frac{1}{3}} = \frac{2}{3} \end{aligned}$$

即 $P(A|\text{开}B) = 1/3, P(C|\text{开}B) = 2/3$ 。这就是后验概率，即我们接受到信息（打开 B 门）后更新了对参数分布 $P(A) = P(C) = 1/3$ 的理解。我们可以看到，这时候 A 门后是汽车的概率没有变化，而 C 门后是汽车的概率则提高了一倍！要想提高抽中的概率，最好换一下门。

在统计学领域，有两个对立的学派，贝叶斯学派和经典学派（频率学派），它们的区别在于如何看待被估计的未知参数。贝叶斯学派的观点是将其视作已知分布的随机变量，它具备某种先验分布。而经典学派将参数 θ 视为待估计的未知常量，经典统计的目标就是提出 θ 的估计方法，并且保证其具有一定的性质，最常用的估计法是最大似然估计（英文是：fisherian estimation，为纪念大统计学家费舍尔 Ronald Fisher，也就是 F 检验的发现者）。而贝叶斯推断则是一种“由果溯因”的思想方法，对参数的估计会随着新的数据的到来而更新为后验分布，因此，**经典统计是去求最大的似然，而贝叶斯统计是求最大的后验**。贝叶斯定理的一般表述如下，其中 θ 是待估参数（因）， x 为观测值 data set 是（果），由结果推断其成因。贝叶斯公式 (1 式) 可以改写为：

$$P(\theta|x) = \frac{P(x|\theta)P(\theta)}{P(x)} \quad (2)$$

这四个概率表达式的意义分别为：

1. $P(\theta)$ ：先验分布 (prior)，它反映的是在观测到任何数据之前我们对待估计参数 θ 的理解和认识。
2. $P(x|\theta)$ ：似然 (likelihood) 概率，代表观测过程，它表示在观测数据（结果）已知的情况下，某个参数（原因）取特定值的可能性。对于固定的 x ， $P(x|\theta)$ 作为 θ 的一个函数就被称为似然函数。
3. $P(\theta|x)$ ：后验分布 (posterior)，这是我们感兴趣的部分，是通过贝叶斯定理得到的最终的分析结果，反映的是在给定观测数据的基础上，我们对于参数的新的认知。
4. $P(x)$ ：证据 (evidence)，一个与我们待估计的参数 θ 无关的边缘概率。它是后验概率计算过程中的归一化系数 (normalizing factor)，通常为了满足后验概率分布加和为 1 的要求。我们可以对所有可能的参数求积分之后得到这个变量： $P(x) = \int_{\Theta} P(x, \theta) d\theta$ 。在离散的形式下，其表达即为： $P(x) = \sum_{\theta} P(x|\theta)P(\theta)$ 。这也就是全概率公式。

贝叶斯公式 (2 式) 用文字描述就是：Posterior = Likelihood $\times$ Prior $\div$ Evidence.

有时贝叶斯公式可以简化为一个正比关系：

$$P(\theta|x) \propto P(x|\theta)P(\theta)$$

此因果关系用文字表述就是：

$$P(\text{状态}|\text{观测}) = \eta \cdot P(\text{观测}|\text{状态})P(\text{状态})$$

更确切的说，“状态”为因，“观测”为果：

$$P(\text{因}|\text{果}) = \eta \cdot P(\text{果}|\text{因})P(\text{因})$$

贝叶斯统计对概率的思维方式比频率学派更切合科学思维。在三门问题中，我们对于因、或者参数分布的原有理解是各占 $1/3$ ，然而在接收到测试数据（也就是果）之后，我们更新了对参数分布的理解，它们不再相等。

把参数理解为随机的变量和未知的常量，世界观就有如此大的不同。随机性是我们理解世界的重要底层逻辑，而极少有人能深刻理解这一点。

附录：贝叶斯公式的推导

我们首先需要明确几个概念，然后才能推出两个重要的公式：全概率公式和贝叶斯公式。

定义（条件概率）：条件概率考虑的是，在事件 B 已经发生的条件下，事件 A 发生的概率，表示为 $P(A|B)$ ，它的一般定义为：

$$P(A|B) = \frac{P(AB)}{P(B)}$$

从条件概率的定义，立即可以得到： $P(AB) = P(A|B)P(B) = P(B|A)P(A)$ ，是谓**乘法定理**。

定义 (划分): 设 S 为试验 E 的样本空间, $B_1, B_2, \dots, B_n$ 为 E 的一组事件, 若:

(i). $B_i B_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$.

(ii). $B_1 \cup B_2 \cup \dots \cup B_n = S$.

则称 $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分。易知对每次试验, 事件 $B_1, B_2, \dots, B_n$ 中必有一个且仅有一个发生。

全概率公式

设实验 E 的样本空间为 S , A 为 E 的事件, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且 $P(B_i) > 0 (i = 1, 2, \dots, n)$, 由于

$$A = AS = A(B_1 \cup B_2 \cup \dots \cup B_n) = AB_1 \cup AB_2 \cup \dots \cup AB_n$$

则可以得到

$$\begin{aligned} P(A) &= P(AB_1) + P(AB_2) + \dots + P(AB_n) \\ &= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n) \end{aligned} \quad (3)$$

(3) 式: $P(A) = \sum_{j=1}^n P(A|B_j)P(B_j)$ 就是所谓全概率公式。以 $n = 3$ 为例, 下图形象的解释了样本空间的划分和全概率公式:




图 1: 样本空间的划分和全概率公式示意

$B_1, B_2, \dots, B_n$ 作为样本空间的划分, 可以看成“因”; 事件 A 就是这一系列成因下发生的事件, 可以看成“果”。而全概率公式 (3 式) 可以看成: 由各种原因推理出结果事件发生的概率, 是由因到果的、正向的思维方式。

贝叶斯公式

设试验 E 的样本空间为 S , A 为 E 中的事件, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且 $P(A) > 0, P(B_i) > 0 (i = 1, 2, \dots, n)$, 则有

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}, \quad i = 1, 2, \dots, n. \quad (4)$$

(4) 式称为贝叶斯公式, 它的证明过程是简单的。

证明. 由条件概率的定义及全概率公式即得:

$$P(B_i|A) = \frac{P(B_i A)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}, \quad i = 1, 2, \dots, n.$$

把它写开来，就是：

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \cdots + P(A|B_n)P(B_n)} \quad \square$$

如前所述， $B_1, B_2, \dots, B_n$ 可以看成“因”，而事件 A 可以看成“果”。那么贝叶斯公式将未知的条件概率 $P(B|A)$ 转化为已知的条件概率 $P(A|B)$ ，即利用已知的条件概率 $P(\text{果}|\text{因})$ ，来求解未知的 $P(\text{因}|\text{果})$ 。贝叶斯公式最终求得的是条件概率 $P(B_i|A)$ ，其物理意义是在观察到结果事件 A 已经发生的情况下，反推“这个结果是由原因 B_i 造成”的概率，简言之就是**由果推因**。

我们说，单纯的概率 $P(B_i)$ 叫做**先验概率**，指的是在没有别的前提信息情况下，根据经验估计得到的概率。而 $P(B_i|A)$ 叫做**后验概率**，它表示在获取信息 A 之后，我们对 B_i 出现的概率的更新的理解，因此后验概率是在先验概率获取了新信息之后的一种修正。

在(3)式和(4)式中取 $n = 2$ ，那么全概率公式和贝叶斯公式就分别成为：

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$$

以及

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})}$$

后者即三门问题中使用过的(1)式。