

最小二乘法讲义

ZYX

问题：求最优直线 $y = ax + b$ ，使得通过 n 个数据点 $(x_i, y_i), (i = 1, 2, \dots, n)$ 的总偏差最小。比如，求通过 3 个点 $(1, 1)$ ， $(2, 2)$ 和 $(3, 2)$ 的最优直线方程。如下图所示：




图 1: 用最小二乘法拟合 3 个数据点

所谓误差即真实值减去理论值，即 $e_i = y_i - p_i$ ，之所以平方，是为了衡量两者靠近的程度，直接相减的结果会有正有负，总和就抵消了，而绝对值不好处理。

一、通过多元微积分求极值的方法

1. 理论推导

写出误差函数： $E = \sum_{i=1}^n (ax_i + b - y_i)^2$ ，这是关于未知系数 a 和 b 的二元函数。

求驻点，得：

$$\begin{cases} \frac{\partial E}{\partial a} = 2 \sum_{i=1}^n (ax_i + b - y_i)x_i = 0 \\ \frac{\partial E}{\partial b} = 2 \sum_{i=1}^n (ax_i + b - y_i) = 0 \end{cases}$$

由此得出关于 a, b 的线性代数方程组：

$$\begin{cases} \left(\sum_{i=1}^n x_i^2 \right) a + \left(\sum_{i=1}^n x_i \right) b = \sum_{i=1}^n x_i y_i \\ \left(\sum_{i=1}^n x_i \right) a + nb = \sum_{i=1}^n y_i \end{cases} \quad (1)$$

根据 Cauchy-Schwarz 不等式：

$$\left(\sum_{i=1}^n x_i\right)^2 = \left(\sum_{i=1}^n 1 \cdot x_i\right)^2 < \sum_{i=1}^n 1^2 \sum_{i=1}^n x_i^2 = n \sum_{i=1}^n x_i^2 \quad (2)$$

其中严格的不等号来自 $x_1, x_2, \dots, x_n$ 互不相等。由此可知，线性方程组的系数行列式不等于零，所以方程组有唯一解，即有唯一的驻点。计算二阶导数：

$$\begin{cases} \frac{\partial^2 E}{\partial a^2} = 2 \sum_{i=1}^n x_i^2 \\ \frac{\partial^2 E}{\partial a \partial b} = 2 \sum_{i=1}^n x_i \\ \frac{\partial^2 E}{\partial b^2} = 2n \end{cases}$$

故 Hessian 矩阵是：

$$2 \begin{bmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & n \end{bmatrix}$$

由于 $\sum_{i=1}^n x_i^2 > 0$ 及不等式 (2)，可知这是一个严格正定的方阵，所以这唯一的驻点就是最小值。由方程组 (1) 可知，所求的直线方程是：

$$\begin{vmatrix} x & y & 1 \\ \sum_{i=1}^n x_i & \sum_{i=1}^n y_i & n \\ \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i y_i & \sum_{i=1}^n x_i \end{vmatrix} = 0 \quad (3)$$

2. 实际应用

就上面的例子来说，计算通过 3 个点 (1,1), (2,2) 和 (3,2) 的回归直线，需要计算如下几个参数：

$\sum_{i=1}^3 x_i = 6, \sum_{i=1}^3 y_i = 5, \sum_{i=1}^3 x_i y_i = 11, \sum_{i=1}^3 x_i^2 = 14$ ，代入方程 (3)，可得最优直线的方程是：

$$\begin{vmatrix} x & y & 1 \\ 6 & 5 & 3 \\ 14 & 11 & 6 \end{vmatrix} = 0$$

化简得： $-3x + 6y - 4 = 0$ ，即最优直线为： $y = \frac{1}{2}x + \frac{2}{3}$ 。

二、通过线性代数求解

在实际的工程计算中，不会使用上面的多变量微积分方法，因为它需要计算偏导矩阵 (Jacobian)，即需要计算 $\sum x_i, \sum y_i, \sum x_i y_i, \sum x_i^2$ 等参数，计算量太大，在处理大规模数据时效率较低。在处理最小二乘问题时，MATLAB 实际采用线性代数的方法，如 \ 运算符或者 `polyfit`, `lsqnonlin` 等函数，其底层原理是都基于矩阵分解，如 QR 分解或奇异值分解 (SVD)，这些算法具有更高的数值稳健性、效率及通用性，它们都是从最基础的正则方程优化而来。

1. 正则方程理论推导

求通过 n 个数据点 (x_i, y_i) 的最优直线 $y = ax + b$ ，可以理解为求解关于系数 a 和 b 的线性方程组：

$$\begin{cases} x_1 a + b = y_1 \\ x_2 a + b = y_2 \\ \dots \\ x_n a + b = y_n \end{cases}$$

可以写成矩阵方程 $\mathbf{Ax} = \mathbf{b}$ 的形式，其中：

$$\mathbf{A} = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

在实际应用中，方程 $\mathbf{Ax} = \mathbf{b}$ 往往是无解的，因为方程数 n 远大于未知量的个数（2 个）： $n \gg 2$ 。从线性空间的角度理解，所谓 $\mathbf{Ax}$ 是矩阵 $\mathbf{A}$ 各列的线性组合，即矩阵 $\mathbf{A}$ 的列空间 $\mathbb{C}(\mathbf{A})$ ，方程无解即右侧向量 $\mathbf{b}$ 不在矩阵 $\mathbf{A}$ 的列空间 $\mathbb{C}(\mathbf{A})$ 之中。最小二乘的任务就是为一个无解的方程组，找到一个最优解 $\hat{\mathbf{x}}$ ，这个最优解表示矩阵 $\mathbf{A}$ 的各列的合适的线性组合，使得此列组合 $\mathbf{A}\hat{\mathbf{x}}$ 与 $\mathbf{b}$ 的距离最小，即 $\mathbf{A}\hat{\mathbf{x}}$ 是向量 $\mathbf{b}$ 在列空间 $\mathbb{C}(\mathbf{A})$ 中的投影。

也可以这样理解，对于无解的方程组 $\mathbf{Ax} = \mathbf{b}$ ，只要想办法微调右侧向量 $\mathbf{b}$ ，将它变成矩阵 $\mathbf{A}$ 的列空间 $\mathbb{C}(\mathbf{A})$ 中最靠近它的那个，也就是找到 $\mathbf{b}$ 在列空间中的投影 $\mathbf{p}$ ，那么无解方程组可以转换为有解的方程组 $\mathbf{A}\hat{\mathbf{x}} = \mathbf{p}$ 。

根据线代的知识，将向量投影到列空间 $\mathbb{C}(\mathbf{A})$ 的投影矩阵是 $\mathbf{A}(\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T$ （推证过程省略），因此 $\mathbf{b}$ 在列空间中的投影向量 $\mathbf{p} = \mathbf{A}\hat{\mathbf{x}} = \mathbf{A}(\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T\mathbf{b}$ ，此式左侧同乘以 $\mathbf{A}^T$ ，得：

$$\mathbf{A}^T\mathbf{A}\hat{\mathbf{x}} = (\mathbf{A}^T\mathbf{A})(\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T\mathbf{b} = \mathbf{A}^T\mathbf{b}$$

即 $\mathbf{A}^T\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^T\mathbf{b}$ ，这叫做正则方程 (Normal equation)。即如果方程组 $\mathbf{Ax} = \mathbf{b}$ 无解，只要在方程组两边同乘 $\mathbf{A}^T$ ，就可以得到一个可解的方程组 $\mathbf{A}^T\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^T\mathbf{b}$ ，其解 $\hat{\mathbf{x}}$ 与 $\mathbf{x}$ 不同，是最优解，它作用于矩阵 $\mathbf{A}$ 的各列，产生的向量 $\mathbf{p}$ 是 $\mathbf{b}$ 在列空间 $\mathbb{C}(\mathbf{A})$ 中的投影。

从 n 维空间回到二维平面，最优解 $\hat{\mathbf{x}}$ 正好是最小二乘法中所求的系数 a 和 b 。

2. 另外的推证方法

普通的最小二乘法就是寻找最优估计 $\hat{\mathbf{x}}$ 使得距离的平方 $E = \|\mathbf{b} - \mathbf{Ax}\|^2$ 最小：

$$E = \|\mathbf{b} - \mathbf{Ax}\|^2 = (\mathbf{b} - \mathbf{Ax})^T(\mathbf{b} - \mathbf{Ax}) = \mathbf{b}^T\mathbf{b} - \mathbf{b}^T\mathbf{Ax} - \mathbf{x}^T\mathbf{A}^T\mathbf{b} + \mathbf{x}^T\mathbf{A}^T\mathbf{Ax}$$

中间的两项是标量。对 $\mathbf{x}$ 求导，得：

$$\frac{\partial E}{\partial \mathbf{x}} = \frac{\partial (\mathbf{b}^T\mathbf{b} - \mathbf{b}^T\mathbf{Ax} - \mathbf{x}^T\mathbf{A}^T\mathbf{b} + \mathbf{x}^T\mathbf{A}^T\mathbf{Ax})}{\partial \mathbf{x}} = -2\mathbf{A}^T\mathbf{b} + 2\mathbf{A}^T\mathbf{Ax}$$

令导数为零，即可得到最小二乘的正则方程：

$$\mathbf{A}^T\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^T\mathbf{b}$$

这个方法比较抽象，不如上述从几何视角的推导便于理解。

3. 实际应用

如前所述，本例的线性模型： $\mathbf{Ax} = \mathbf{b}$ 写下来就是：

$$\begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

这个方程是无解的，计算正则方程 $\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b}$ 对应的系数：

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix} = \begin{bmatrix} 14 & 6 \\ 6 & 3 \end{bmatrix}, \quad \mathbf{A}^T \mathbf{b} = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 11 \\ 5 \end{bmatrix}$$

因此方程 $\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b}$ 具体就是：

$$\begin{bmatrix} 14 & 6 \\ 6 & 3 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} 11 \\ 5 \end{bmatrix}$$

它是有解的，易解得：

$$\hat{\mathbf{x}} = \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{2}{3} \end{bmatrix}$$

这就是所求得的最优组合，即最优直线为： $y = \frac{1}{2}x + \frac{2}{3}$ 。

代入原方程验证：

$$\begin{cases} p_1 = \frac{7}{6} \\ p_2 = \frac{5}{3} \\ p_3 = \frac{13}{6} \end{cases}, \quad \begin{cases} e_1 = -\frac{1}{6} \\ e_2 = \frac{1}{3} \\ e_3 = -\frac{1}{6} \end{cases}$$

即：投影向量 $\mathbf{p} = \left(\frac{7}{6}, \frac{5}{3}, \frac{13}{6}\right)$ ，误差向量 $\mathbf{e} = \left(-\frac{1}{6}, \frac{1}{3}, -\frac{1}{6}\right)$ ，两者相加，得：

$$\mathbf{p} + \mathbf{e} = \begin{bmatrix} \frac{7}{6} \\ \frac{5}{3} \\ \frac{13}{6} \end{bmatrix} + \begin{bmatrix} -\frac{1}{6} \\ \frac{1}{3} \\ -\frac{1}{6} \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \mathbf{b}$$

两者的内积为零，即两者垂直：

$$\mathbf{p} \cdot \mathbf{e} = -\frac{7}{6} \cdot \frac{1}{6} + \frac{5}{3} \cdot \frac{1}{3} - \frac{13}{6} \cdot \frac{1}{6} = 0$$

即： $\mathbf{p}$ 是向量 $\mathbf{b}$ 在列空间 $\mathbb{C}(\mathbf{A})$ 中的投影，而误差向量 $\mathbf{e}$ 垂直于列空间 $\mathbb{C}(\mathbf{A})$ ，两者相加正好等于原向量 $\mathbf{b}$ 。

其几何意义解释于下图：其中 $\mathbf{x}_1$ 与 $\mathbf{x}_2$ 分别是矩阵 $\mathbf{A}$ 的两列，容易知道它们张成的平面的法向量

是 $\mathbf{n} = \mathbf{x}_1 \times \mathbf{x}_2 = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & 2 & 3 \\ 1 & 1 & 1 \end{vmatrix} = (-1, 2, -1)$ ，因此平面方程是： $-x + 2y - z = 0$ ，它就是矩阵 $\mathbf{A}$ 的列

空间 $\mathbb{C}(\mathbf{A})$ 。法向量所在的一维直线其实就是矩阵 $\mathbf{A}$ 的左零空间 $\mathbb{N}(\mathbf{A}^T)$ 。左零空间是垂直于列空间，即 $\mathbb{N}(\mathbf{A}^T) \perp \mathbb{C}(\mathbf{A})$ 。关于矩阵的四个子空间的说明补充于附录。方程组无解，是因为右侧向量 $\mathbf{b}$ 并不属于

$\mathbb{C}(\mathbf{A})$ 。而最小二乘的任务，就是通过正则方程，找到列空间 $\mathbb{C}(\mathbf{A})$ 中距离 $\mathbf{b}$ 最近的向量，即向量 $\mathbf{b}$ 在 $\mathbb{C}(\mathbf{A})$ 上的投影 $\mathbf{p}$ ，从而找到最优的列组合 $\hat{\mathbf{x}}$ 使得 $\mathbf{A}\hat{\mathbf{x}} = \mathbf{p}$ 。这样做得到的误差向量 $\mathbf{e}$ 其实是在矩阵的左零空间中，是向量 $\mathbf{b}$ 在左零空间中的投影。




图 2: 在本例的最小二乘中，向量在两个子空间投影关系

三、附：矩阵的几个基本子空间

线性代数基本定理 (Fundamental Theorem of Linear Algebra) 描述了矩阵的空间结构，若 $\mathbf{A}$ 是一个 $m \times n$ 的矩阵，如果其秩为 r ，它的四个基本子空间及其维度是：

- 1). 列空间 (Column Space)，记为 $\mathbb{C}(\mathbf{A})$. 它是所有列向量的线性组合。它在 $\mathbf{R}^m$ 空间中，维度为 r .
- 2). 零空间 (Nullspace)，记为 $\mathbb{N}(\mathbf{A})$. 它是方程 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 的解空间。它在 $\mathbf{R}^n$ 空间中，维度为 $n - r$.
- 3). 行空间 (Row Space)，记为 $\mathbb{C}(\mathbf{A}^T)$. 它是 $\mathbf{A}$ 的行的所有线性组合，即 $\mathbf{A}^T$ 的列的所有组合。它在 $\mathbf{R}^n$ 空间中，行空间与列空间维度相同，亦为 r .
- 4). 左零空间 (Left Nullspace)，即 $\mathbf{A}^T$ 的零空间，记为 $\mathbb{N}(\mathbf{A}^T)$. 它在 $\mathbf{R}^m$ 空间中，维度为 $m - r$. 注：为何叫它左零空间？ $\mathbf{A}$ 的转置的零空间，即 $\mathbf{A}^T\mathbf{y} = \mathbf{0}$ 的解空间，如果要把 $\mathbf{y}$ 放在左边，此方程取转置变为： $\mathbf{y}^T\mathbf{A} = \mathbf{0}^T$ ：

$$\begin{bmatrix} \mathbf{A}^T \\ \end{bmatrix} \begin{bmatrix} \mathbf{y} \\ \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ \end{bmatrix} \xrightarrow{\text{取转置}} \begin{bmatrix} \mathbf{y}^T \\ \end{bmatrix} \begin{bmatrix} \mathbf{A} \\ \end{bmatrix} = \begin{bmatrix} \mathbf{0}^T \\ \end{bmatrix}$$

这就变成了一个行向量 $\mathbf{y}^T$ 左乘矩阵 $\mathbf{A}$ 的形式，此为名取“左零”的原因。

列空间与左零空间互相垂直： $\mathbb{C}(\mathbf{A}) \perp \mathbb{N}(\mathbf{A}^T)$ ，它们将 m 维空间分成了两个相互正交的子空间，它们的维度加起来，正好等于 $\mathbf{A}^T$ 的列的数目（即 $\mathbf{A}$ 的行的个数）；同理，行空间 $\mathbb{C}(\mathbf{A}^T) \perp$ 零空间 $\mathbb{N}(\mathbf{A})$ ，它

们将 $\mathbf{R}^n$ 分成了两个相互正交子空间，它们的维度加起来，正好是 $\mathbf{A}$ 的列的数目。四个子空间的几何直观如下图所示。本例中出现的两个子空间是列空间、左零空间。




图 3: 任一矩阵 $\mathbf{A}_{m \times n}$ 的四个基本子空间与正交性

以上内容请参考Gilbert Strang教授的《线性代数》课程及相关书籍。